

策略模型结构图

输入：图结构 G + 查询 q

欧拉化序列化

Prolonged Format: Node-Attr-Edge-Attr

预训练的图结构编码器

Graph Eulerian Transformer Encoder

Transformer层 X 24
(注意力头: 12)

跨模态投影 (Projector)

MLP

GELU

MLP

文本解码器

Qwen2.5-7B-Instruct

LoRA 适配层

微调目标模块: W_q, W_k, W_v, W_o
Rank $r=64$, Alpha=128

输出生成

基于组间相对策略优化的强化学习微调

组间采样 ($G=5$)

针对同一Query采样一组轨迹

采样轨迹 1 (o_1)

采样轨迹 ... (o_i)

采样轨迹 G (o_G)

可验证奖励模型
(Verifiable Reward Model)

$$R = \alpha + \beta + \gamma$$

α 答案正确性
调用NetworkX
计算真值
匹配正确: +1.0

β 拓扑一致性
解析思维链中的边
是否存在
存在: + δ , 不存在: - δ

γ 格式一致性与
语义输出格式规范
格式正确
给予奖励

优势估算 (Advantage Estimation)
不需要评判模型

KL散度约束

参考模型 (π_{ref})
冻结的监督微调模型

策略更新
(Policy Update)

梯度反向传播 (仅更新 LoRA)